Neurociência computacional na identificação do fenótipo da Doença de Fabry

Ana Sofia Pinto[1211040], Lícia Almeida[1211459]

Instituto Superior de Engenharia do Porto

Mestrado em Engenharia Biomédica

Unidade Curricular: Neurociência Computacional

Docentes: Goreti Marreiros, Lorena Rodrigues, Diogo Martinho

Abstract. A Doença de Fabry é uma condição genética, causada por mutações no gene GLA, resultando na deficiência da enzima α-galactosidase A. Essa deficiência provoca a acumulação de substâncias lipídicas nos lisossomas, afetando principalmente o sistema cardiovascular, renal e nervoso. O diagnóstico precoce é essencial para melhorar o prognóstico dos pacientes, no entanto, existe um grande desafio devido à variabilidade dos sintomas e à subdiagnosticação da doença. Este trabalho consiste na aplicação da neurociência computacional na deteção de fenótipos da Doença de Fabry, utilizando, nomeadamente, redes neuronais (*feedforward*, MLP, RBF) e algoritmos artificiais (SVM). As redes neuronais *feedforward* e MLP foram as que apresentaram um melhor desempenho na identificação do fenótipo da doença nos pacientes diagnosticados. Por fim, conclui-se que essas ferramentas são complementares ao diagnóstico clínico e essenciais para um diagnóstico e terapia adequada, permitindo uma análise mais detalhada e automatizada, com elevada sensibilidade e especificidade.

Keywords: Doença de Fabry · Neurociência Computacional · Redes Neuronais · Algoritmos Artificiais

1 Introdução

Na primeira secção do presente relatório será feita uma breve introdução teórica à Doença de Fabry, bem como, uma abordagem dos sintomas e tratamentos para a mesma.

1.1 Doença de Fabry

A doença de Fabry (DF) é uma doença de sobrecarga lisossomal hereditária ligada ao cromossoma X [1], causado por mutações no gene GLA, resultando na deficiência da atividade enzimática da α-galactosidase A [2]. Esta enzima tem

aproximadamente 429 aminoácidos e é responsável por decompor a globotriaosilceramida (Gb3) em galactose e lactosilceramida, nos lisossomas [3]. Assim, a deficiência da enzima leva a uma acumulação destes glicoesfingolípidos, resultando na formação de inclusões lipídicas e estruturas multilamelares que afetam a função celular. A acumulação ocorre em muitos tipos de células, incluindo os gânglios da raiz dorsal, as células neuronais do sistema nervoso autónomo e muitas outras [1].

A DF pode ser causada por várias mutações. Além disso, a correlação entre o genótipo e o fenótipo é complexa, pois a mesma mutação pode determinar diferentes manifestações clínicas. Isto pode ser atribuído tanto a fatores ambientais como ao grupo sanguíneo ou ao sexo [3].

As mutações no GLA, que causam uma atividade enzimática praticamente nula (<5% do valor normal), estão associadas a fenótipos clássicos graves e de início precoce, caracterizados pelo desenvolvimento de manifestações clínicas na infância ou adolescência, enquanto que as mutações que levam a uma atividade enzimática residual estão associadas a fenótipos atenuados e de início tardio, caracterizados pelo desenvolvimento de manifestações cardíacas, renais e/ou cerebrovasculares na idade adulta [4].

De acordo com a Associação Portuguesa de Doenças do Lisossoma (APL), em 2020, foi estimado que a incidência anual, incluindo, na análise, variantes da doença que acontecem em fases mais tardias, foi de 1 em 3000 casos [5].

Mundialmente, a prevalência média estimada aquando do nascimento é de aproximadamente 1 em 15000. É importante ter em consideração que a doença de Fabry é uma condição clínica subdiagnosticada e a frequência poderá ser maior [6].

1.2 História

A doença de Fabry, também conhecida por *Anderson-Fabry*, foi descoberta no século XIX, em 1898, pelos doutores *Johannes Fabry* e *William Anderson*. Inicialmente, Fabry relatou um caso de um jovem, de 14 anos, com lesões cutâneas generalizadas, púrpura nodular hemorrágica e albuminúria, bem como, demonstrava diminuição da capacidade de exercício físico e perda de peso, enquanto que Anderson descreveu um adulto de 39 anos com sintomas sistémicos como proteinúria e linfedema, varizes nas pernas, entre outros [7].

Em 1947, foi descoberta a natureza da doença sendo esta proveniente de uma acumulação de um lípido e, em 1967, a causa desse depósito lipídico foi identificada com a deficiência da enzima α-galactosidase A [8].

Finalmente, em 1986, o gene responsável pela condição foi identificado, possibilitando o desenvolvimento de melhores tratamentos como a terapia de substituição enzimática, que veio a ser utilizada mais tarde, nos anos 2000 [9]. Em alternativa a esta terapia, surgiu a terapia de *chaperone*, aprovada pela primeira vez em 2016, na Alemanha, pela FDA (*Food Drug Administration*) [10].

1.3 Hereditariedade

Sendo a DF uma condição genética no cromossoma X, onde se encontra o gene GLA, esta é transmitido através desse cromossoma e varia conforme o progenitor afetado.

As mulheres apresentam 50% de probabilidade de transmitir o gene mutado em cada gravidez, já que possuem dois cromossomas X. No entanto, se um dos cromossomas for afetado o outro pode ter uma cópia funcional do gene [7, 11]. Assim, esta patologia afeta, maioritariamente, os indivíduos masculinos.

Os homens portadores do gene com mutação transmitem-no apenas às filhas do sexo feminino [11].

O modo de transmissão da doença nas situações em que o portador é o pai ou a mãe encontra-se representado pelo esquema da Fig.1, em a) e b), respetivamente.

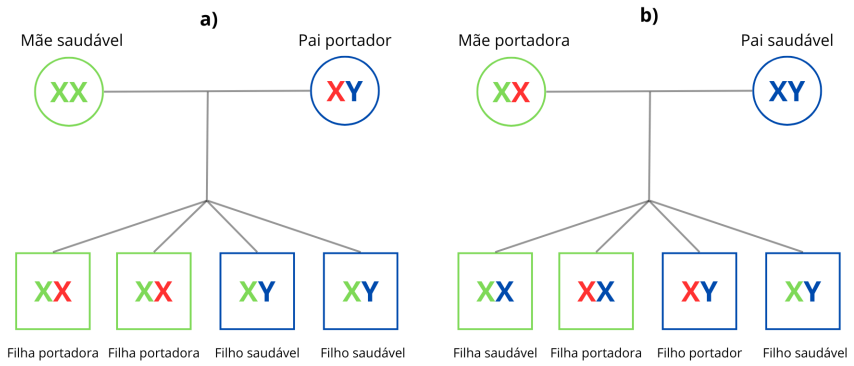

Fig. 1. Modo de transmissão da doença de Fabry, nos casos de a) pai portador e b) mãe portadora. Adaptado de [7].

1.4 Sintomas

Os pacientes com DF apresentam frequentemente sintomas desde a infância, sendo comuns as acroparestesias devido à neuropatia periférica de pequenas fibras. Estas acroparestesias causam sensações de ardor, picadas ou dormência nas extremidades e estão associadas a uma dor neuropática significativa. Outros sintomas incluem hipohidrose, levando a alterações na termorregulação e ao esforço físico. Além disso, as biópsias cutâneas de pacientes com DF revelam uma

menor densidade de inervação na pele, onde há deposição de Gb3 [12–14]. Outra manifestação característica da infância é a córnea verticilada, identificável por um padrão de depósitos dourados ou acinzentados na parte inferior da córnea [12].

Na fase adulta, as complicações da DF podem incluir progressão para insuficiência renal, doenças cardíacas e problemas cerebrovasculares. No caso da insuficiência renal, o comprometimento é evidenciado pela presença de células epiteliais vacuoladas e podócitos afetados tanto nos glomérulos quanto nos túbulos distais. A taxa de filtração glomerular diminui gradualmente, e homens com formas clássicas da doença podem desenvolver insuficiência renal terminal antes dos 50 anos [12, 14].

No coração, a acumulação de Gb3 impacta diversos tipos de células e tecidos, incluindo miócitos, células endoteliais vasculares, células musculares lisas, o endocárdio, os fibroblastos das válvulas cardíacas e o sistema de condução. As manifestações cardíacas mais frequentes são a hipertrofia ventricular esquerda (HVE), palpitações, arritmias, dispneia e doenças de pequenos vasos coronários [13, 14].

A DF também afeta o sistema nervoso central, podendo levar a doenças cerebrovasculares precoces. A acumulação de glicoesfingolípidos e o espessamento das paredes vasculares provocam um estreitamento dos microvasos cerebrais, aumentando o risco de ataques isquémicos transitórios e acidentes vasculares cerebrais. O sistema nervoso autónomo é igualmente comprometido, resultando em sintomas como dores abdominais e possíveis distúrbios gastrointestinais, frequentemente relatados por pacientes [14].

Por fim, estima-se que mais de 70% dos pacientes com DF apresentem sinais cutâneos, sendo os angioqueratomas os mais característicos. Estes surgem, em geral, na região pélvica, dentro do umbigo e, nos homens, no escroto [14].

Essas manifestações clínicas, que podem ser variáveis e progressivas, destacam a necessidade de um acompanhamento cuidadoso para monitorizar e tratar as complicações associadas a esta doença.

1.5 Tratamentos

Apesar de ainda não ter sido descoberta uma cura para a doença de Fabry, existem tratamentos terapêuticos que podem facilitar a vida dos doentes, sendo os mais utilizados a terapia de reposição enzimática (ERT) e a terapia de *chaperone*.

A ERT é uma das abordagens mais antigas e amplamente usadas, que consiste na administração de uma versão recombinante da enzima α-galactosidase A (r-αGLA A), de forma a repor a atividade enzimática que os pacientes com Fabry não têm. Atualmente, existem duas formas de ERT aprovadas pela FDA: Replagal (α-GLA 1 mg/kg a cada duas semanas) e a Fabrazyme (β-GLA 0,2 mg/kg a cada duas semanas). Ambas ajudam a reduzir a acumulação de Gb3 em vários tecidos, retardando a progressão dos sintomas renais, cardíacos e cerebrais [9, 15]. A terapia de *chaperone* é representada pelo medicamento *migalastat*, e, é uma terapia oral indicada para pacientes com mutações específicas da doença de Fabry [10]. A função dos *chaperones* é estabilizar a enzima α-galactosidase A

mutante, permitindo que esta seja corretamente dobrada e transportada para os lisossomas, onde pode desempenhar a sua função [16, 17].

Para além das terapias anteriormente referidas, já aprovadas pela FDA, existem outras em fase de desenvolvimento. A Terapia de Redução de Substrato (SRT) visa reduzir a quantidade de Gb3 produzida, limitando a carga sobre os lisossomas. Dois exemplos de SRT, atualmente em estudo, são o *venglustat* e o *lucerastat*, que atuam inibindo a síntese de glicoesfingolipídos, com o objetivo de aliviar os sintomas ao diminuir a acumulação de Gb3. E finalmente, a terapia genética e a terapia baseada em mRNA, que consistem na correção da mutação subjacente na doença de Fabry, permitindo que as células do paciente produzam a enzima α-galactosidase A de forma adequada, e, na produção temporária da enzima através da introdução de mRNA exógeno, respetivamente [17].

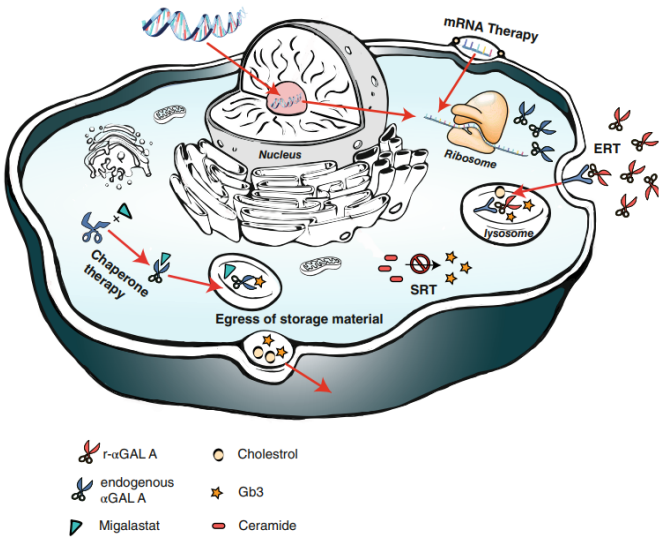

Fig. 2. Demonstração do funcionamento das diferentes terapias utilizadas no tratamento da doença de Fabry [17].

2 Neurociência Computacional

A neurociência computacional é uma área que tem como objetivo principal compreender o cérebro e como este utiliza sinais elétricos e químicos para representar e processar informações, criando modelos que expliquem o funcionamento neuronal em diferentes níveis, desde o molecular e celular até aos sistemas que controlam comportamentos mais complexos. Nos últimos anos, a neurociência computacional tem avançado significativamente permitindo obter simulações mais

realistas de redes neuronais, e um maior desenvolvimento de modelos simplificados, facilitando o estudo de grandes redes de neurónios. Desta forma, esta ciência adquire um papel papel fundamental no desenvolvimento de teorias sobre o funcionamento do cérebro [18].

2.1 Redes neuronais

As redes neuronais tornaram-se uma ferramenta poderosa no campo do *deep learning* e da inteligência artificial, permitindo a aproximação de funções e dinâmicas através da aprendizagem a partir de exemplos. Uma rede neuronal artificial aproxima-se dos dois extremos da modelação da função cerebral, sendo capaz de modelar neurónios individuais e as suas dinâmicas com um detalhe biológico, utilizando algoritmos compostos por unidades que combinam múltiplas entradas para produzir uma única saída [19].

Existem vários modelos de redes neuronais, incluindo redes neuronais recorrentes, *feedforward*, de função de base radial e convolucionais.

Nas redes neuronais recorrentes, cada neurónio calcula a sua saída como uma função não linear da sua entrada integrada, utilizando pelo menos um ramo de retroalimentação [20]. Estas redes são utilizadas para investigar as propriedades dinâmicas das redes corticais, modelar a atividade de redes de neurónios e representar processos cerebrais, como percepção, memória e atenção, devido à sua capacidade de recordar entradas anteriores [21, 22].

Por outro lado, as redes neuronais *feedforward* são mais simples, permitindo que a informação flua apenas numa direção, desde os nós de entrada até aos nós de saída, passando por quaisquer nós ocultos que possam existir. Estas redes têm sido amplamente utilizadas em tarefas de classificação, previsão e extração de características [23]. As redes neuronais *feedforward* podem ainda ser classificadas como redes de uma ou múltiplas camadas [22].

As redes neuronais de função de base radial utilizam funções de base radial como funções de ativação, incluindo funções como a gaussiana, multiquadrática e exponencial. Têm diversas aplicações, como aproximação de funções, previsão de séries temporais e controlo de sistemas [22].

Por fim, as redes neuronais convolucionais são compostas por camadas convolucionais, camadas de *pooling* e uma camada totalmente conectada em uma camada oculta [23]. A camada convolucional tem como objetivo aprender representações de características das entradas, produzindo mapas de características. A camada de *pooling* realiza uma extração secundária de características, reduzindo as dimensões dos mapas de características e aumentando a robustez da extração. A última camada totalmente conectada é seguida por uma camada de saída [21]. As redes neuronais convolucionais destacam-se pela sua capacidade de aprender automaticamente e de forma eficaz as representações das características mais relevantes [20].

2.2 Algoritmos artificiais

A Inteligência Artificial (IA) é uma disciplina ampla, que surgiu na década de 1950, e, abrange não só algoritmos, bem como a aplicação de diversas tecnologias com o objetivo de desenvolver máquinas/sistemas inteligentes que possam ampliar ou até mesmo substituir atividades humanas. Os algoritmos de inteligência artificiais são métodos codificados para resolver problemas ou executar tarefas específicas de maneira eficiente, aplicando a lógica de forma prática. No contexto da IA, os algoritmos desempenham um papel fundamental, uma vez que são usados para imitar leis naturais e comportamentos humanos, criando sistemas que podem tomar decisões, reconhecer padrões e aprender com dados, permitindo que essas tecnologias executem tarefas complexas, como o reconhecimento de padrões em imagens ou o processamento de dados sensoriais [24].

3 Estado de arte

Os algoritmos artificiais têm desempenhado um papel crucial na melhoria do diagnóstico e tratamento da doença de Fabry.

No contexto de *deep learning*, diferentes algoritmos foram aplicados de forma a melhorar a deteção precoce desta doença. Um exemplo é a aplicação de um algoritmo de Regressão Logística (LR), uma técnica estatística simples, utilizada para prever a probabilidade de um paciente ter Fabry com base em variáveis clínicas. Este modelo é eficaz na rápida distinção entre pacientes com Fabry e pacientes saudáveis, e, dessa forma, particularmente útil para encontrar pacientes subdiagnosticados ou que ainda não foram identificados corretamente [25, 26]

Além disso, existem técnicas como a *Support Vector Machine* (SVM) (criar fronteiras de separação entre pacientes com diferentes condições), enquanto o *Random Forest* (RF) (baseado em árvores de decisão que combina várias árvores para fazer previsões mais precisas) e o *K-Nearest Neighbors* (KNN) (algoritmo de classificação que faz previsões com base nas características dos exemplos mais próximos), ajudaram a classificar e identificar pacientes de acordo com suas semelhanças clínicas e características de exames, melhorando a precisão e robustez do diagnóstico [26].

Outro método, descrito em [27], foi denominado Processamento de Linguagem Natural (NLP) foi crucial para a análise de registos eletrónicos de saúde (EHRs), através do qual, a partir de dados textuais não estruturados, o algoritmo conseguiu identificar sintomas relevantes relacionados à Doença de Fabry, facilitando o reconhecimento precoce da condição e auxiliando os médicos na interpretação rápida de grandes volumes de dados.

Além dos algoritmos artificiais, as redes neuronais também têm mostrado uma precisão interessante no diagnóstico da doença de Fabry.

Em [28] foram utilizadas redes neuronais convolucionais para o diagnóstico da doença, a partir de imagens de sedimentos urinários. O modelo foi treinado usando um conjunto limitado de imagens ampliadas por técnicas de aumento de dados e extraíndo segmentos positivos e negativos (sem sinais da doença)

para treinar a rede neuronal. O diagnóstico através da rede demonstrou grande precisão, com sensibilidade de 90,2% e especificidade de 97,7%, conseguindo assim identificar corretamente a maioria dos casos de Fabry (sensibilidade) e de excluir a maioria dos controles saudáveis (especificidade).

Assim, pode dizer-se que tanto os algoritmos computacionais como as redes neuronais ajudam no suporte ao diagnóstico da Doença de Fabry, apesar de nenhum deles substituir o diagnóstico clínico feito por médicos, funcionando como ferramentas complementares para identificar possíveis casos e permitir que os médicos façam um diagnóstico mais informado e precoce [27].

4 Identificação do fenótipo através de redes neuronais

Nesta secção são apresentados os modelos desenvolvidos para a identificação do fenótipo da DF. A identificação precoce deste parâmetro, quer seja benigno, clássico ou não-clássico, é imprescindível para direcionar intervenções médicas e melhorar diagnósticos/previsões clínicas. Neste projeto utilizamos abordagens de *machine learning*, incluindo redes neuronais *feedforward*, *Radial Basis Function* (RBF), *Multi-Layer Perceptron* (MLP), entre outras, e modelos de classificação, de forma a auxiliar no diagnóstico do fenótipo.

4.1 Descrição dos fenótipos

A DF apresenta três tipos principais de fenótipo: o benigno, o clássico e o não-clássico. O fenótipo clássico está relacionado com mutações que resultam numa atividade enzimática praticamente nula, sendo caracterizado pelo início precoce dos sintomas, geralmente durante a infância ou adolescência. Já o fenótipo não-clássico, também conhecido como fenótipo de início tardio, está associado a mutações que preservam alguma atividade residual da enzima. Esse fenótipo manifesta-se na idade adulta, com sintomas menos graves e, frequentemente, restritos a órgãos específicos. A sua progressão é mais lenta e menos severa em comparação com o fenótipo descrito anteriormente. Apesar de ser mais comum, o fenótipo não-clássico foi historicamente subdiagnosticado devido à sua apresentação clínica de menor evidência. Em casos de início tardio com progressão extremamente lenta e manifestações leves podem ser classificados como benignos [29]. Desta forma, a identificação e diferenciação dos fenótipos é essencial para decisões médicas e terapêuticas, garantindo intervenções adequadas para cada paciente.

4.2 Descrição do *dataset* e redes utilizadas

O *dataset* escolhido era, inicialmente, constituído por informações sobre pacientes diagnosticados com DF, incluindo dados clínicos, genéticos e laboratoriais, nomeadamente, *sex* (sexo do paciente), *Number of patients* (número de pacientes com características semelhantes), *Phenotype* (Tipo de fenótipo clínico - *Classical, Non-Classical, Benign*), *AAVariant* e *AAvariantShort*(contém

informação sobre variantes de aminoácidos na proteína GBA), *DNAMutation* (contém informação sobre mutações no DNA), *LeuEnzymAct_number* e *LeuEnzymAct* (número de pacientes em que a atividade enzimática foi medida, e, nível de atividade enzimática relacionado à enzima α-galactosidase A, respetivamente), *LysoGb3_number* e *LysoGb3* (número de pacientes em que o nível de LysoGb3 foi medido, e, valores de LysoGb3 - biomarcador, respetivamente). A partir desses dados, foi realizada uma redução para balancear o número de pacientes associados a cada fenótipo, garantindo que cada grupo tivesse 29 pacientes. Essa abordagem foi adotada para equilibrar o conjunto de dados e obter resultados mais fidedignos em análises posteriores. De seguida, são apresentadas as redes neuronais utilizadas ao longo do desenvolvimento do projeto, bem como a descrição e a implementação de cada uma, de forma a criar algoritmos que permitissem identificar os fenótipos da DF com base em pacientes já diagnosticados. Cada modelo foi treinado com 70% dos dados do *dataset*, e testado e avaliado com os restantes 30%.

4.2.1 Rede *Feedforward*

Uma rede neuronal *feedforward* é um tipo de rede neuronal artificial em que as conexões entre os neurónios seguem uma única direção, ou seja, partem dos neurónios da camada de entrada para a camada de saída, passando pelas camadas ocultas [30]. Não existem ciclos ou conexões que retornem às camadas anteriores, caracterizando o seu funcionamento como unidirecional. Este tipo de rede é normalmente utilizado em problemas de regressão e classificação devido à sua simplicidade e eficácia. Na camada de entrada, a rede recebe os dados que representam as variáveis independentes do problema. Essas informações são processadas nas camadas ocultas (*hidden*), onde são aplicadas funções de ativação que permitem capturar relações não lineares entre as variáveis. Por fim, a camada de saída fornece o resultado final, que pode ser uma previsão ou uma classificação [30]. As arquiteturas das redes neuronais influenciam como o modelo aprende e generaliza os padrões de dados. Redes simples, com menos camadas e neurónios, capturam relações lineares e são rápidas de treinar, mas têm uma capacidade limitada para problemas complexos. Arquiteturas intermédias, com duas camadas ocultas e neurónios moderados, equilibram o aprendizado e a generalização, sendo adequadas para padrões não lineares moderados. Redes complexas, com três ou mais camadas, capturam relações altamente sofisticadas, mas treinam o modelo lentamente e são propensas a *overfitting*, especialmente em conjuntos de dados pequenos. Para evitar esse problema, técnicas de regularização, como *dropout*, e conjuntos de treino maiores são essenciais [30]. A rede *feedforward* utilizada foi projetada para classificação dos pacientes nos três fenótipos da DF. Na camada de entrada, a rede recebe os atributos necessários para o diagnóstico do fenótipo - *sex, AAvariantShort, DNAMutation, LeuEnzymAct_median, LysoGb3_median* - correspondentes ao número de neurónios de entrada (5 neurónios). Foram testadas diversas arquiteturas para identificar a mais adequada aos dados e ao objetivo final. O número de camadas ocultas foi ajustado com o parâmetro *hidden* (Fig. 3), que controla a quantidade de neurónios em cada camada oculta e o número total de camadas na rede. As

arquiteturas testadas incluíram arquiteturas simples: uma camada oculta com 5 neurónios (*hidden = c(5)*), uma camada oculta com 10 neurónios (*hidden = c(10)*); arquiteturas intermédias: duas camadas ocultas com 5 e 3 neurónios (*hidden = c(5, 3)*), e, duas camadas ocultas com 8 e 4 neurónios (*hidden = c(8, 4)*); e, uma arquitetura complexa: três camadas ocultas com 10, 6 e 3 neurónios (*hidden = c(10, 6, 3)*).

```
nn_model <- neuralnet(
  formula,
  data = train_model_data,
  hidden = c(5,3),
  linear.output = FALSE,
  act.fct = "logistic",
  lifesign = "minimal",
  stepmax = 1e6,
  threshold = 0.01
)
```

Fig. 3. Configuração da rede neuronal *feedforward*, em R, utilizando o pacote *neuralnet*, com duas camadas ocultas (5 e 3 neurónios).

Todas as camadas ocultas utilizam a função de ativação logística, que enquadra os valores de entrada numa escala entre 0 e 1. A camada de saída da rede tem 3 neurónios porque existem 3 fenótipos a serem classificados (*benign, classical* e *non-classical*).

4.2.2 Rede *Multi-Layer Perceptron*

Um modelo *Multi-Layer Perceptron* (MLP) é uma rede composta por *perceptrons* [31]. Possui uma camada de entrada, responsável por receber os sinais de entrada; uma camada de saída, encarregada de realizar previsões ou tomar decisões para os dados fornecidos; e camadas intermediárias, conhecidas como camadas ocultas, localizadas entre a entrada e a saída. O número de camadas ocultas pode ser ajustado conforme a necessidade, permitindo maior flexibilidade na arquitetura da rede. O MLP é amplamente utilizado em problemas de aprendizagem supervisionada, sendo especialmente utilizado para tarefas de classificação, onde é treinado com base no conjunto de dados fornecido. Durante a fase de treino, o MLP aprende as relações entre os dados de entrada e as saídas desejadas. Nesse processo, ele ajusta os parâmetros do modelo, como os pesos, com o objetivo de minimizar os erros e melhorar sua precisão [31]. A rede neuronal *Multi-Layer Perceptron* foi utilizada para classificação dos pacientes nos três fenótipos da DF. Na camada de entrada, a rede recebe os atributos necessários para o diagnóstico do fenótipo, ou seja, os mesmos já referidos para a rede *feedforward*. O modelo foi criado com 10 neurónios na camada oculta,

com um decaimento (*decay*) de 0,01, de forma a evitar *overfitting*, ajuste excessivo aos dados de treino. Foi ainda configurado o parâmetro "*linout = FALSE*", indicando que a rede será usada para classificação, não para regressão, e que o modelo usará uma função de ativação *softmax*.

4.2.3 Rede com *Radial Basis Function*

Uma rede *Radial Basis Function* (RBF) é uma rede neuronal implementada para resolver problemas de classificação e regressão, com uma estrutura simples composta por três camadas: entrada, oculta e saída. Na camada de entrada, os dados são recebidos e enviados diretamente para a camada oculta. A camada oculta contém neurónios que utilizam funções de base radial, geralmente uma Gaussiana, para calcular o quanto cada ponto de entrada está próximo de um centro específico no espaço. Esses centros representam regiões particulares dos dados e são determinados durante o treino usando algoritmos como o *k-means* [32]. O treino desta rede ocorre em duas etapas: na primeira, os centros e larguras das funções Gaussianas são definidos com base nos dados; e, de seguida, os pesos da camada de saída são ajustados, de forma supervisionada, para minimizar o erro. Durante a inferência, os neurónios calculam ativações com base na proximidade aos centros, e essas ativações são combinadas para gerar a saída. Esta abordagem permite que as redes RBF sejam altamente eficazes em aproximar funções não lineares, classificando ou ajustando dados com rapidez e precisão, para além de apresentarem robustez e simplicidade computacional [32]. O modelo implementado com a rede RBF foi também projetado para a classificação do fenótipo dos dados fornecidos. A camada de entrada da rede é composta por variáveis que caracterizam a identificação dos fenótipos utilizados nas redes anteriores. A camada oculta da rede utiliza um *kernel* do tipo *rbfdot*, característico de redes baseadas na função radial base, que é conhecida pela capacidade de aproximar funções complexas e não lineares. O número de células na camada oculta é ajustado automaticamente pelo algoritmo *ksvm* (da biblioteca *kernlab*), de acordo com os dados de treino. O modelo é treinado utilizando o método *C-svc*, com um parâmetro C=0.1, que controla o equilíbrio entre maximizar a margem e minimizar o erro de classificação nos dados de treino. A camada de saída da rede retorna a classificação prevista do fenótipo, que é comparada com as classes reais no conjunto de teste para avaliação do desempenho do modelo [32].

4.2.4 Rede *Self-Organizing Map* e *Support Vector Machine*

O *Self-Organizing Map* (SOM), é uma rede neuronal projetada para mapear dados de um espaço de alta dimensão para uma grade discreta, composta por unidades neuronais distribuídas numa ou duas dimensões. Cada neurónio armazena um vetor de pesos, e o SOM organiza dados desconhecidos em grupos de padrões semelhantes com base num critério de similaridade, como a distância Euclidiana. Essa rede neuronal é capaz de identificar regularidades e correlações nos dados de entrada, ajustando as suas respostas futuras de acordo com o que aprendeu. Uma característica marcante do SOM é a sua robustez para lidar com

dados ruidosos. Além disso, ele preserva as relações topológicas entre os dados de entrada, ou seja, entradas que são próximas no espaço de entrada tendem a ser mapeadas para neurónios vizinhos na grade do mapa [33]. Neste trabalho, o modelo foi implementado para facilitar a interpretação dos padrões ou *clusters* presentes no conjunto de treino, gerando um mapa de unidades que reflete a estrutura dos dados (Fig. 4).

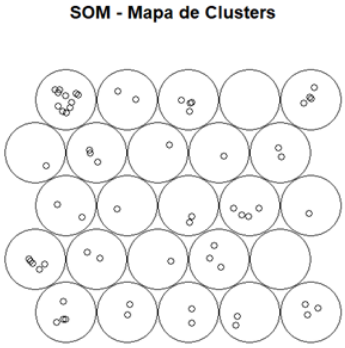

Fig. 4. Mapa de unidades/clusters presentes no conjunto de treino.

Por sua vez, a *Support Vector Machine* (SVM) é um dos algoritmos de aprendizagem supervisionada mais amplamente utilizados, sendo frequentemente aplicada a problemas de classificação em *machine learning*. O seu objetivo principal é criar a melhor linha ou limite de decisão que consiga separar um espaço n-dimensional em diferentes classes, permitindo a classificação precisa de novos pontos de dados. Este limite de decisão ideal é conhecido como hiperplano [34]. A SVM seleciona os pontos ou vetores extremos que ajudam a definir o hiperplano, conforme ilustrado na Fig. 5. Esses pontos extremos, fundamentais para o cálculo do hiperplano, são chamados de vetores de suporte, o que dá origem ao nome do algoritmo. Existem dois tipos principais de SVM: linear e não-linear. A SVM linear é utilizada para dados linearmente separáveis, ou seja, quando um conjunto de dados pode ser dividido em duas classes utilizando uma única linha reta. Nesse caso, os dados são considerados linearmente separáveis, e o classificador aplicado é o classificador SVM linear [34]. Por outro lado, a SVM não-linear é utilizada em situações onde os dados não são linearmente separáveis. Isso ocorre quando um conjunto de dados não pode ser dividido por uma linha reta, sendo então classificado como dados não-lineares. O classificador utilizado nesse caso é o SVM não-linear.

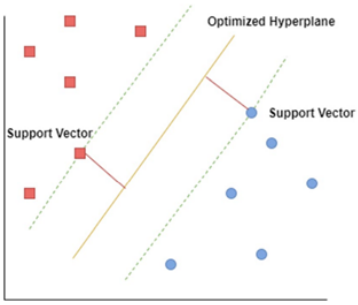

Fig. 5. Descrição gráfica do limite da SVM, demonstrando os vetores de suporte e o hiperplano otimizado para um conjunto de dados [34].

O SVM foi implementado de forma a servir de comparação para os métodos comuns de redes neuronais. O SVM tenta encontrar uma fronteira de decisão que separa as diferentes classes (neste caso, os fenótipos). Utilizou o *kernel* RBF (*Radial Basis Function*), para lidar com a não linearidade entre as variáveis. O parâmetro de regularização é 1 (c=1), controlando o equilíbrio entre maximizar a margem de separação e minimizar o erro de classificação. O *"type = "C-svc""* indica que é de classificação com margens de separação rígidas, uma configuração padrão para classificação em SVM e *"scaled = TRUE"* indica que os dados devem ser normalizados antes do treino.

5 Análise dos resultados

Aqui serão apresentados os resultados e desempenhos de cada rede neuronal utilizada de forma a fazer uma comparação entre as mesmas.

Table 1. Comparação de métricas de desempenho para diferentes redes neurais.

Rede	*Accuracy* (%)	*Precision* (%)			*Recall* (%)		
		B	C	NC	B	C	NC
Feedforward (hidden = c(5))	75	75	75	75	100	75	60
Feedforward (hidden = c(10))	66,7	75	75	50	75	75	50
Feedforward (hidden = c(5,3))	83,3	100	75	75	80	100	75
Feedforward (hidden = c(8,4))	83,3	100	75	75	80	100	75
Feedforward (hidden = c(10, 6, 3))	75	100	75	50	66,7	100	66,7
MLP	83,3	100	75	75	80	100	75
RBF	66,7	25	100	75	100	66,7	60
SVM	66,7	25	100	75	100	66,7	60

A Tabela 1 mostra o desempenho das diferentes arquiteturas da rede neuronal *feedforward* utilizadas para treinar modelo, pelo que podemos retirar que as que obtiveram uma melhor *accuracy* foram as de duas camadas ocultas. Assim, entre as duas, a arquitetura com 5 e 3 neurónios é a melhor escolha já que ambas apresentam desempenho igual, dado que é mais simples, treina o modelo mais rapidamente e tem menor risco de overfitting, mantendo-se a eficácia. Caso num futuro houvesse uma necessidade de maior capacidade de aprendizagem, como por exemplo, mais dados ou maior complexidade nos padrões, poder-se-ia optar pela arquitetura com 8 e 4 neurónios.
Relativamente ao modelo MLP, este apresentou um desempenho semelhante ao do modelo *feedforward* com 3 e 5 neurónios, mostrando-se também uma boa abordagem, com *accuracy* de 83,3%.
Por último, a RBF e o SVM mostraram um desempenho inferior, comparativamente às duas redes neuronais com melhor desempenho, nomeadamente a rede neuronal *feedforward* com duas camadas (com 5 e 3 neurónios) e a MLP. As matrizes de confusão de cada modelo desenvolvido são apresentadas em anexo.
Relativamente aos valores de perda no treino e na validação, todos os modelos apresentaram valores muito reduzidos. Na rede neuronal *feedforward*, apenas foi verificado o valor para o modelo que apresentou melhores resultados, ou seja, com duas camadas (5 e 3 neurónios), apresentando um valor de perda de 0,87% para o treino e de 1,71% para a validação. O modelo que utilizou a rede neuronal MLP verificou uma perda de treino de apenas 0,01% e de 1,97% para a validação. O modelo treinado com rede neuronal RBF apresentou uma perda de treino de 0,75% e 1,37% de perda de validação. Por fim, o algoritmo SVM apresentou resultados semelhantes aos modelos, com perda de treino de 0,23% e perda de validação de 1,38%. Estes resultados reduzidos indicam que o treino dos modelos foi bem-sucedido, já que os mesmos tiveram a capacidade de aprender e generalizar bem. Desta análise retira-se que o modelo *feedforward* (5,3) é o mais equilibrado, apresentando baixa perda no treino, menor complexidade e elevada *accuracy*. O modelo MLP, apesar de apresentar um desempenho semelhante ao anterior, em termos de *accuracy*, pode sofrer de overfitting (grande diferença entre valores de perda no treino e na validação), tornando-se menos robusto. A RBF e o SVM apresentam perdas no treino e na validação baixas, contudo não atingiram a eficácia necessária para o objetivo do projeto. Os gráficos que representam a evolução da perda no treino e na validação, para os modelos descritos, encontram-se em anexo.

6 Conclusão

O diagnóstico da DF, uma patologia genética, é desafiador devido à variabilidade dos sintomas. Além disso, o seu diagnóstico antecipado é crucial para prevenir complicações graves e melhorar o prognóstico dos pacientes. O avanço das tecnologias de *deep learning* tem revolucionado a área da saúde, oferecendo soluções mais precisas e eficientes para o diagnóstico de diversas doenças. Relativamente à DF, o presente trabalho corrobora que tanto redes neuronais como algoritmos artificiais têm sido fundamentais para melhorar a deteção precoce da mesma, oferecendo uma solução mais eficaz e automatizada para a análise de dados clínicos.

A aplicação de redes neuronais, em especial redes neuronais convolucionais, tem se destacado na identificação de padrões específicos associados à DF. Essas redes são capazes de analisar imagens médicas e dados genéticos, extraindo informações relevantes para o diagnóstico. Estudos recentes demonstram que essas ferramentas apresentam alta precisão, com sensibilidade e especificidade superiores a 90%, permitindo uma avaliação mais detalhada e consistente da evolução da doença.

Os algoritmos artificiais também se mostraram bastante úteis, tornando o processo de diagnóstico automatizado, o que não apenas acelera o processo, mas também reduz a possibilidade de erros humanos, garantindo um diagnóstico mais preciso e confiável. Neste contexto, o presente trabalho destacou o potencial de diferentes modelos de treinados a partir de redes neuronais para auxiliar no diagnóstico da DF. A análise revelou que as redes neuronais *feedforward* com duas camadas ocultas (particularmente a arquitetura com 5 e 3 neurónios) apresentaram os melhores resultados em termos de *accuracy* e eficiência, equilibrando desempenho e simplicidade. O modelo MLP demonstrou um desempenho semelhante, tendo-se destacado como uma abordagem viável. Por outro lado, modelos baseados em redes RBF e algoritmos SVM mostraram-se menos adequados para atender às exigências específicas deste estudo, com desempenhos abaixo do esperado.

Assim, concluímos que a introdução dessas tecnologias na medicina é um marco importante, proporcionando uma maior precisão nos diagnósticos e tratamentos, e abrindo caminho para futuras aplicações da inteligência artificial no campo da saúde. O desenvolvimento contínuo desses sistemas pode transformar significativamente a forma como doenças genéticas são diagnosticadas e geridas, trazendo benefícios palpáveis para pacientes e profissionais de saúde.

References

1. L. G. Rodrigues et al., "Neurophysiological, behavioral and morphological abnormalities in the Fabry knockout mice," Neurobiol Dis, vol. 33, no. 1, pp. 48–56, Jan. 2009, doi: 10.1016/j.nbd.2008.09.001.
2. O. Azevedo et al., "Fabry disease and the heart: A comprehensive review," Int. J. Mol. Sci., vol. 22, no 9, p. 4434, May 01, 2021, MDPI. doi: 10.3390/ijms22094434.
3. T. P. Bernardes, R. D. Foresto, and G. M. Kirsztajn, "Fabry disease: Genetics, pathology, and treatment," 2020, Associacao Medica Brasileira. doi: 10.1590/1806-9282.66.S1.10.
4. V. Gragnaniello et al., "Newborn screening for fabry disease in northeastern italy: Results of five years of experience," Biomolecules, vol. 11, no. 7, Jul. 2021, doi: 10.3390/biom11070951.
5. "APL - Associação Portuguesa de Doenças do Lisossoma," 11 novembro 2020. [Online]. Available: https://aplisosoma.org/doencas/doenca-de-fabry/.
6. "Conhecimento sobre doenças raras e medicamentos órfãos," Orphanet, 2 agosto 2024. [Online]. Available: https://www.orpha.net/pt/disease/detail/324.
7. J. Silva, "Terapêutica da doença de Fabry", Dissertação para obtenção do grau de Mestre em Ciências Farmacêuticas, UAlg, Algarve, 2018.
8. H. Mamun, "Fabry's Disease - A comprehensive review on pathogenesis, diagnosis and treatment," Journal of the Pakistan Medical Association, vol. 64, nº 2, pp. 189-194, 2014.
9. R. El Dib, H. Gomaa, R. P. Carvalho, S. E. Camargo, R. Bazan, P. Barretti, and F. C. Barreto, "Enzyme replacement therapy for Anderson-Fabry disease," The Cochrane Database of Systematic Reviews, vol. 7, no. 7, Art. no. CD006663, 2016, doi: 10.1002/14651858.CD006663.pub.
10. J. Müntze, D. Gensler, O. Maniuc, D. Liu, T. Cairns, D. Oder, K. Hu, K. Lorenz, S. Frantz, C. Wanner, and P. Nordbeck, "Oral Chaperone Therapy Migalastat for Treating Fabry Disease: Enzymatic Response and Serum Biomarker Changes After 1 Year," Clinical Pharmacology and Therapeutics, vol. 105, no. 5, pp. 1224–1233, 2019, doi: 10.1002/cpt.1321.
11. D. P. Germain, "Fabry Disease," Orphanet Journal of Rare Diseases, vol. 30, nº 5, pp. 24-26, 2010.
12. C. Valbuena et al., "Kidney histologic alterations in α-galactosidase-deficient mice," Virchows Archiv, vol. 458, no. 4, pp. 477–486, Apr. 2011, doi: 10.1007/s00428-011-1051-8.
13. A. Rita and S. Moura, "Universidade do Minho Escola de Engenharia."
14. S. Lerario et al., "Fabry disease: a rare disorder calling for personalized medicine," Oct. 01, 2024, Springer Science and Business Media B.V. doi: 10.1007/s11255-024-04042-4.
15. X. Li, X. Ren, Y. Zhang, L. Ding, M. Huo, and Q. Li, "Fabry disease: Mechanism and therapeutics strategies," Frontiers in Pharmacology, vol. 13, Art. no. 1025740, 2022, doi: 10.3389/fphar.2022.1025740.
16. F. Weidemann, A. Jovanovic, K. Herrmann, and I. Vardarli, "Chaperone Therapy in Fabry Disease," International Journal of Molecular Sciences, vol. 23, 2022, doi: 10.3390/ijms23031887.
17. S. J. van der Veen, C. E. M. Hollak, A. B. P. van Kuilenburg, and M. Langeveld, "Developments in the treatment of Fabry disease," Journal of Inherited Metabolic Disease, vol. 43, no. 5, pp. 908–921, 2020, doi: 10.1002/jimd.12228.

18. T. J. Sejnowski, C. Koch, and P. S. Churchland, "Computational neuroscience," Science (New York, N.Y.), vol. 241, no. 4871, pp. 1299–1306, 2014, doi: 10.1126/science.3045969.
19. N. Kriegeskorte and T. Golan, "Neural network models and deep learning," Apr. 01, 2019, Cell Press. doi: 10.1016/j.cub.2019.02.034.
20. Y. Zhao et al., "Deep neural network for automatic characterization of lesions on 68Ga-PSMA-11 PET/CT," Eur J Nucl Med Mol Imaging, vol. 47, no. 3, pp. 603–613, Mar. 2020, doi: 10.1007/s00259-019-04606-y.
21. S. Bitzer and S. J. Kiebel, "Recognizing recurrent neural networks (rRNN): Bayesian inference for recurrent neural networks," Biol Cybern, vol. 106, no. 4–5, pp. 201–217, Jul. 2012, doi: 10.1007/s00422-012-0490-x.
22. Abdel-Nasser Sharkawy, "Principle of Neural Network and Its Main Types: Review", J. Adv. Appl. Computat. Math., vol. 7, pp. 8–19, Aug. 2020.
23. M. Kurucan, M. Özbaltan, Z. Yetgin, e A. Alkaya, "Applications of artificial neural network based battery management systems: A literature review", Renew. Sustain. Energy Rev., vol. 192, no 114262, p. 114262, 2024.
24. W. D. Xin Zhang, "Application of artificial intelligence algorithms in image processing," Elsevier Inc., pp. 42-49, 2019.
25. M. J. Hilz, N. Lyn, F. Marczykowski, et al., "Unveiling the untreated: development of a database algorithm to identify potential Fabry disease patients in Germany," Orphanet Journal of Rare Diseases, vol. 19, Art. no. 259, 2024, doi: 10.1186/s13023-024-03258-y.
26. A. Moura, "Detecting important electrocardiogram," Universidade do Minho, 2022.
27. A. Michalski, K. Lis, J. Stankiewicz, S. Kloska e A. e. a. Sycz, "Supporting the Diagnosis of Fabry Disease Using a Natural Language Processing-Based Approach," Journal of Clinical Medicine, vol. 12, nº 3599, 2023.
28. H. Uryu et al., "Automated urinary sediment detection for Fabry disease using deep-learning algorithms," Mol Genet Metab Rep, vol. 33, Dec. 2022, doi: 10.1016/j.ymgmr.2022.100921.
29. O. Azevedo et al., "Natural history of the late-onset phenotype of Fabry disease due to the p.F113L mutation," Mol Genet Metab Rep, vol. 22, Mar. 2020, doi: 10.1016/j.ymgmr.2020.100565.
30. F. Fei and D. Wang, "Application of Neural Network Feedforward in Fuzzy PI Controller for Electric Vehicle Thermal Management System: Modeling and Simulation Studies," Energies (Basel), vol. 17, no. 1, Jan. 2024, doi: 10.3390/en17010009.
31. J. Joy, A. Kannan, S. Ram, and S. Rama, "Speech emotion recognition using neural network and MLP classifier," Ijesc, vol. 2020, pp. 25170-25172, 2020.
32. W. Bowen, "Research on nonlinear calibration of mine catalytic-combustion-based combustible-gas sensor based on RBF neural network," Heliyon, vol. 9, no. 3, Mar. 2023, doi: 10.1016/j.heliyon.2023.e14055.
33. D. Tian and L. Fan, "A Brain MR Images Segmentation Method Based on SOM Neural Network," 2007 1st International Conference on Bioinformatics and Biomedical Engineering, Wuhan, China, 2007, pp. 686-689, doi: 10.1109/ICBBE.2007.179.
34. Kurani, A., Doshi, P., Vakharia, A. et al. A Comprehensive Comparative Study of Artificial Neural Network (ANN) and Support Vector Machines (SVM) on Stock Forecasting. Ann. Data. Sci. 10, 183–208 (2023). https://doi.org/10.1007/s40745-021-00344-x

7 Anexos

Nos anexos encontram-se as matrizes confusão de todos os modelos treinados.

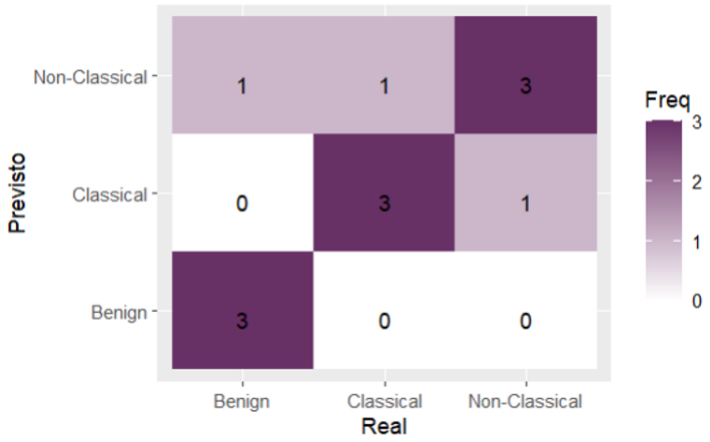

Fig. 6. Matriz de confusão para modelo treinado rede neuronal feedforward de uma camada com 5 neurónios.

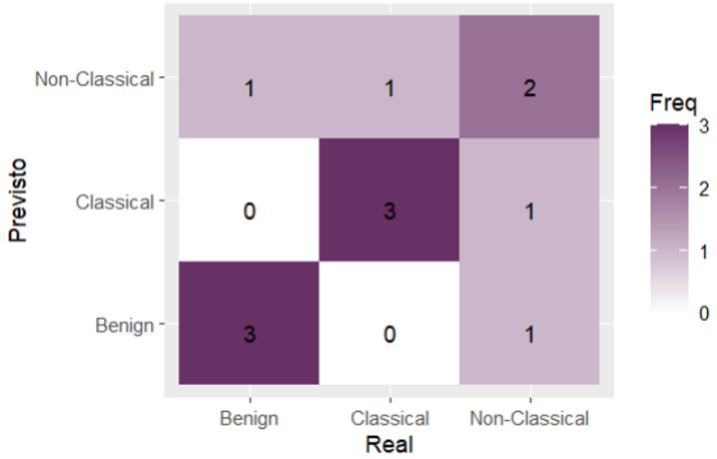

Fig. 7. Matriz de confusão para modelo treinado rede neuronal feedforward de uma camada com 10 neurónios.

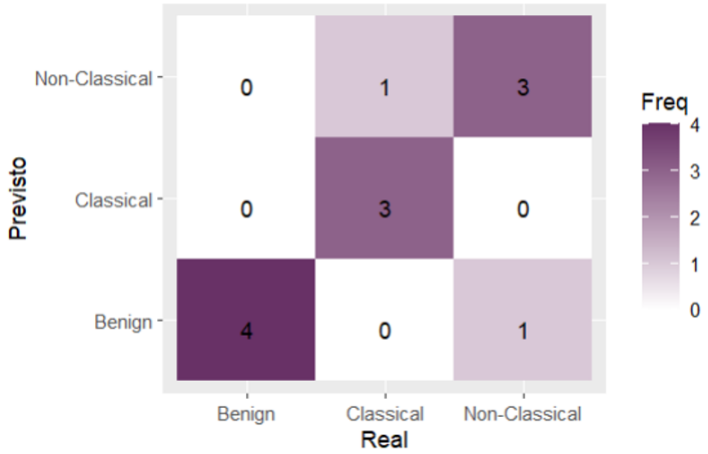

Fig. 8. Matriz de confusão para modelo treinado rede neuronal feedforward de duas camadas com 5 e 3 neurónios.

Fig. 9. Matriz de confusão para modelo treinado rede neuronal feedforward de duas camadas com 8 e 4 neurónios.

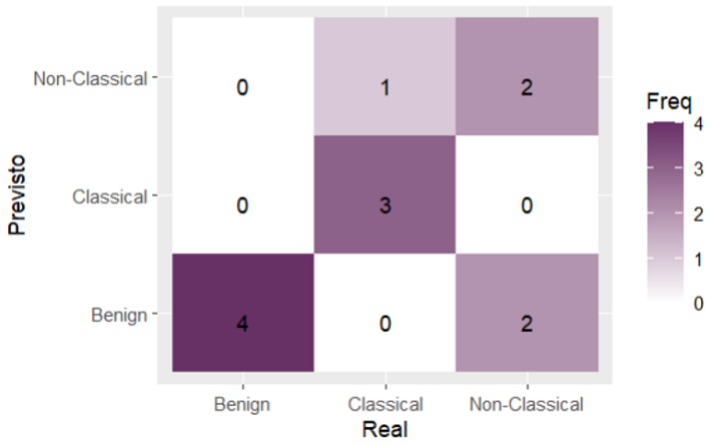

Fig. 10. Matriz de confusão para modelo treinado rede neuronal feedforward de três camadas com 10, 6 e 3 neurónios.

Fig. 11. Matriz de confusão para modelo treinado rede neuronal MLP.

Fig. 12. Matriz de confusão para modelo treinado rede neuronal RBF.

Fig. 13. Matriz de confusão para modelo treinado com SVM.

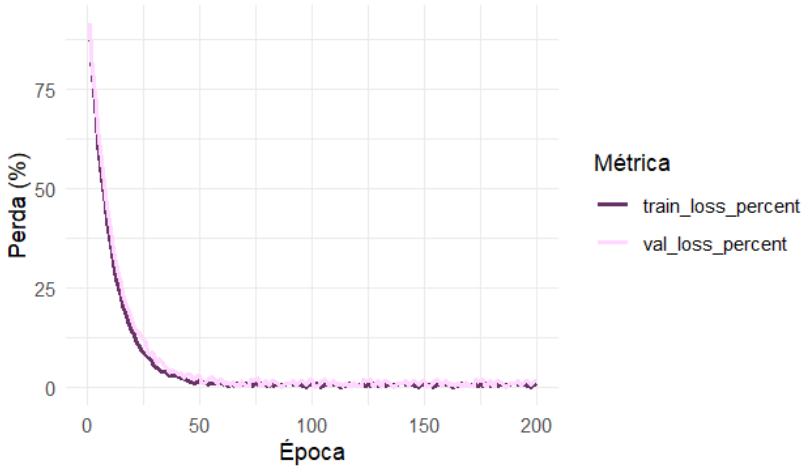

Fig. 14. Gráfico da evolução da perda no treino e validação no modelo treinado com rede neuronal *feedforward* de duas camadas (5 e 3 neurónios).

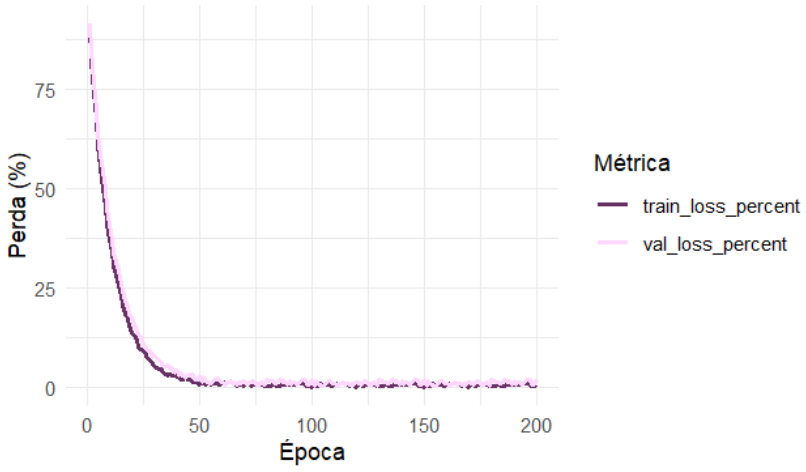

Fig. 15. Gráfico da evolução da perda no treino e validação no modelo treinado com rede neuronal MLP.

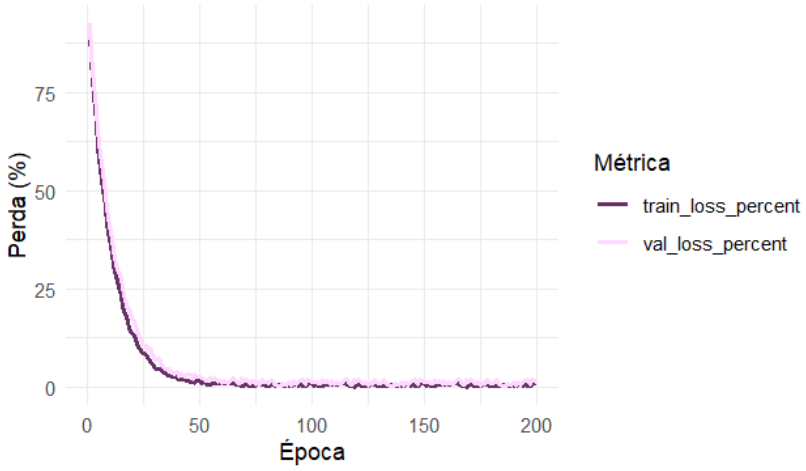

Fig. 16. Gráfico da evolução da perda no treino e validação no modelo treinado com rede neuronal RBF.

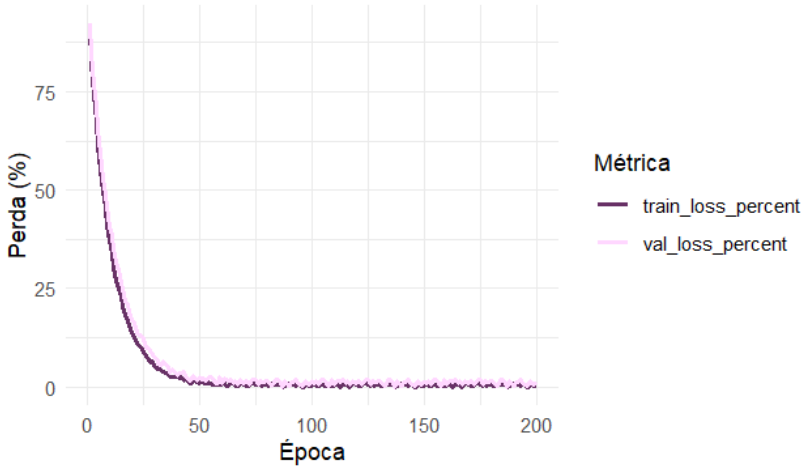

Fig. 17. Gráfico da evolução da perda no treino e validação no modelo treinado com SVM.