Relatório

Reconhecimento de emoções básicas através da voz

Ana Sofia Pinto [1,2], Lícia Almeida [1,3], Pedro Prata [1,4], Luís Coelho[1,5] e Luís Mourão[1,6]

[1] Instituto Superior de Engenharia do Porto, Instituto Politécnico do Porto, Rua Dr. António Bernardino de Almeida, 431, 4249-015 Porto, Portugal;
[2] 1211040@isep.ipp.pt, [3] 1211459@isep.ipp.pt, [4] 1211122@isep.ipp.pt, [5] lfc@isep.ipp.pt, [6] lnm@isep.ipp.pt

Resumo: O reconhecimento de emoções adquire um papel de grande importância na interação humana, influenciando decisões e comportamentos em diversos domínios, como a educação, a saúde mental e diferentes tecnologias. O presente relatório explora a implementação de modelos que permitem o reconhecimento de emoções através da voz, aproveitando os avanços na inteligência artificial, aprendizagem automática e processamento de linguagem natural. O projeto utilizou duas bibliotecas principais: Librosa e OpenSMILE, sendo a primeira utilizada, normalmente, para análise de sinais de áudio, fornecendo características como MFCCs e *Mel Spectrogram*, enquanto que a OpenSMILE consiste na extração de características acústicas relevantes para tarefas paralinguísticas. Os modelos finais foram obtidos a partir de preparação dos dados do *dataset* escolhido, treino e teste do mesmo até que este permitisse detetar emoções em tempo real. A análise comparativa revelou um desempenho superior da abordagem baseada no Librosa, que alcançou uma precisão de 80%, em comparação com o OpenSMILE, que obteve 67% no mesmo parâmetro. Assim, destaca-se o potencial da extração robusta de características de áudio para o reconhecimento de emoções, através da biblioteca Librosa. O presente estudo sublinha ainda a importância da integração de sistemas emocionalmente inteligentes para promover uma interação homem-máquina mais natural e empática.

Palavras-Chave: reconhecimento de emoções básicas, interação homem-máquina, processamento de áudio, aprendizagem automática

1. Introdução

As emoções influenciam decisões e comportamentos, sendo essenciais em contextos como educação, saúde mental e tecnologia assistida. O reconhecimento de emoções através da voz está associado ao avanço da inteligência artificial, *machine learning* e processamento de linguagem natural (NLP), permitindo criar sistemas mais sensíveis e precisos. Este tipo de interação enriquece a comunicação, pois as máquinas não apenas compreendem palavras, mas também captam emoções, tornando o processo mais humano. O reconhecimento de emoções por voz é uma tecnologia com aplicações emergentes em várias áreas, como robôs de assistência social, sistemas de *neurofeedback*, veículos autónomos e condução inteligente, permitindo que as máquinas "entendam" e "respondam" emocionalmente aos seres humanos, da mesma forma que interagem com outros humanos. Este facto tem impulsionado o desenvolvimento do mercado de dispositivos inteligentes e empáticos, que tem crescido de forma exponencial nos últimos anos [1]. Assim, a escolha deste tema visa promover interações mais inclusivas, eficazes e emocionalmente inteligentes, com impacto positivo em diversas áreas da sociedade, incluindo novos avanços em robótica e sistemas autónomos.

Para o desenvolvimento deste projeto foram utilizadas duas bibliotecas principais: Librosa e OpenSMILE. A primeira consiste numa biblioteca integrada no *Python* projetada para análise de sinais de áudio e música, comummente utilizada na recuperação de informações musicais e em aplicações de processamento de sinais. Esta oferece várias funcionalidades tais como operações em séries temporais, cálculos de espectrogramas e extração de características como *Mel-Frequency Cepstral Coefficients* (MFCCs) e *Mel Spectrogram*, essenciais no reconhecimento de padrões de áudio [2]. Por outro lado, o OpenSMILE é uma ferramenta que adquire uma grande importância na extração de características acústicas em tarefas paralinguísticas, como reconhecimento de emoções e deteção de estados na voz. Esta biblioteca fornece conjuntos padronizados de características, que incluem medidas relacionadas com prosódia, espectro e qualidade da voz. Desta forma, tem sido bastante utilizado em estudos de deteção de distúrbios da fala, demonstrando a sua robustez e aplicabilidade em contextos diversificados [3].

O presente relatório foi desenvolvido no âmbito da Unidade Curricular de Interação Homem-Máquina, lecionada no 1º ano de Mestrado em Engenharia Biomédica, no Instituto Superior de Engenharia do Porto, e descreve o projeto implementado, que teve como objetivo a implementação de técnicas para a deteção automática de emoções humanas, utilizando um *dataset* com um conjunto de dados de áudio como fonte principal. Desta forma, este relatório abrange desde a fundamentação científica sobre teorias das emoções até à construção de um modelo computacional capaz de identificar emoções a partir de um *dataset*.

1.1. Definição de Emoção

As emoções podem ser compreendidas como processos psiconeurais complexos que desempenham um papel crucial na regulação de comportamentos e decisões humanas. Elas resultam de interações entre variáveis subjetivas (como experiências individuais) e objetivas (como estímulos externos), mediadas por sistemas neuronais e hormonais. Essas interações são responsáveis por desencadear experiências afetivas distintas, como prazer ou desprazer, e gerar processos cognitivos, incluindo avaliações e a identificação de estímulos emocionalmente relevantes. Além disso, as emoções ativam mudanças tanto psicológicas quanto fisiológicas, preparando o organismo para responder às condições do ambiente. Cada emoção possui uma “tonalidade de sentimento” própria, que ajuda a codificar os valores intrínsecos das interações, dependendo de sua contribuição para a sobrevivência imediata ou a longo prazo. Estas também motivam comportamentos adaptativos, muitas vezes expressivos e orientados a objetivos. Por fim, as experiências subjetivas associadas às emoções emergem da interação de sistemas emocionais com os substratos cerebrais fundamentais do "eu". Estes processos são cruciais para a assimilação de novas informações, a recuperação de eventos passados e a tomada eficiente de decisões em situações futuras [4].

1.1.1. Teoria das Emoções

As teorias de emoções adquirem uma grande importância no estudo das emoções humanas. A teoria de Paul Ekman é uma das que mais influenciam o estudo das emoções humanas. Este autor propôs que existem um conjunto de emoções básicas universais, isto é, compartilhadas por todas as culturas, independentemente das diferenças socioculturais. Segundo Ekman existem seis emoções básicas: alegria, tristeza, raiva, medo, nojo e surpresa. Mais tarde, acrescentou o desprezo como sétima emoção básica. Essas emoções básicas possuem padrões de expressão facial universais, o que significa que pessoas em qualquer parte do mundo, mesmo sem terem contato com outras, são capazes de reconhecer essas expressões emocionais. Desta forma, Ekman baseou as suas conclusões em estudos que associaram expressões faciais específicas a emoções particulares, e posteriormente, as suas descobertas foram ampliadas com o estudo das microexpressões, expressões faciais rápidas e involuntárias que revelam emoções que uma pessoa pode tentar

ocultar. A universalidade das emoções propostas teve um impacto significativo em diversas áreas, como no reconhecimento de emoções em ambientes clínicos, na segurança e na psicologia social. Por exemplo, em ambientes clínicos, a compreensão das expressões faciais universais de emoções tem sido utilizada para tratar condições como autismo ou transtornos de ansiedade, enquanto em segurança, a identificação de microexpressões pode ser usada para detetar mentiras ou intenções de risco [5], [6].

Ao contrário da teoria proposta por Ekman, a teoria dimensional de James Russell propõe que as emoções não devem ser vistas como categorias isoladas, mas como variações contínuas num espaço bidimensional. Russell sugeriu que as emoções podem ser representadas em dois eixos principais: valência e ativação, nas quais a valência refere-se à qualidade da emoção, que pode ser positiva (como a alegria) ou negativa (como a tristeza). Por outro lado, a ativação descreve o grau de energia associado a uma emoção, variando entre baixo (como o relaxamento) e alto (como a excitação ou a raiva intensa). Este modelo dimensional é útil na representação de emoções de forma mais flexível, permitindo a compreensão de estados emocionais que não podem ser facilmente classificados em categorias discretas, como a confusão ou a ambivalência emocional, que podem ter aspetos tanto positivos como negativos. Esta teoria tem sido aplicada em áreas que mapeiam diferentes emoções num espaço contínuo, facilitando a análise de dados emocionais em contextos como o reconhecimento emocional automatizado (usado em *softwares* de análise de voz, vídeo ou texto) [7], [8].

Essas teorias não só proporcionam uma base sólida para o entendimento das emoções humanas, bem como oferecem *insights* importantes para a criação de tecnologias que procuram compreender e interagir com as emoções em diversas áreas de aplicação.

1.1.2. Relevância da Deteção de Emoções na Interação Homem-máquina

Como referido anteriormente, a deteção de emoções na interação homem-máquina (IHM) é fundamental para melhorar a naturalidade e eficácia dessas interações. A capacidade de sistemas reconhecerem e interpretarem emoções humanas torna as interações mais intuitivas, promovendo respostas adaptativas e personalizadas. Essa competência é especialmente relevante em contextos como robótica assistida, educação e saúde, onde a sensibilidade emocional pode amplificar a eficácia e aceitação da tecnologia. Além disso, sistemas equipados com inteligência emocional artificial conseguem adaptar as suas respostas com base em sinais emocionais captados por voz, expressões faciais, gestos corporais ou dados fisiológicos. Essa abordagem multimodal tem potencial para revolucionar a IHM, ao oferecer interações mais empáticas e envolventes, com aplicações que variam de suporte a saúde mental à personalização em ambientes educativos e de entretenimento [9], [10].

1.2. Deteção de Emoções

A deteção de emoções utiliza diversas modalidades para identificar estados emocionais humanos. As principais abordagens incluem técnicas baseadas em áudio, vídeo e texto, cada uma com vantagens específicas dependendo do contexto em que são utilizadas. A análise de áudio destaca-se por explorar características como o tom de voz, o ritmo e a melodia da fala, elementos que frequentemente refletem padrões emocionais. Essa abordagem é particularmente vantajosa em cenários onde dados visuais não estão disponíveis, como chamadas telefónicas ou interações com assistentes virtuais. Por meio do áudio, é possível inferir estados emocionais como felicidade, raiva ou tristeza, mesmo quando as palavras são neutras. Modalidades baseadas em vídeo, por sua vez, analisam expressões faciais e movimentos corporais, fundamentais para interpretar emoções de maneira visual. Essa abordagem é amplamente utilizada em contextos como vigilância, diagnósticos clínicos e interação homem-máquina. As expressões faciais universais, como as propostas por Paul Ekman, são particularmente úteis nesse tipo de análise. A análise de texto, por outro lado, baseia-se em técnicas de NLP para identificar emoções implícitas no uso de palavras, frases e contextos. De entre estas modalidades, a escolha do áudio

apresentou-se como um desafio devido às suas características específicas, já que, embora a voz humana seja uma rica fonte de sinais emocionais, a variabilidade no ritmo, tom de voz e melodia da fala são parâmetros que requerem abordagens robustas para extração e interpretação precisa dessas características. Por exemplo, fatores como sotaques, ruídos de fundo e estilos de fala podem dificultar a identificação confiável das emoções. No entanto, apesar das dificuldades que poderiam ser enfrentadas, o áudio foi selecionado por ser uma modalidade que permite a transmissão de emoções em tempo real, um aspeto essencial para aplicações práticas em sistemas automatizados [5], [11], [12].

2. Estado da Arte

O reconhecimento de emoções através da voz tem sido uma das áreas mais estudadas ao longo do tempo, utilizando diferentes técnicas de extração de características de áudio e criando diferentes modelos de redes neuronais.

Em [13], foi abordado o reconhecimento de emoções em tempo real com base em áudios, combinando técnicas de extração de características acústicas e redes neuronais recorrentes (RNN). De forma a extrair as características de áudio foi utilizado o *toolkit openSMILE*. Exemplos de atributos extraídos são coeficientes MFCC, frequência fundamental, energia e medidas relacionadas à voz, resultando em 130 características a cada intervalo de 10 ms. De seguida, estas foram processadas com a abordagem *Bag of Audio Words* (*BoAW*), que cria representações compactas e fixas para cada segmento de áudio. O modelo criado, com uma RNN baseada em *GRUs (Gated Recurrent Units*) atingiu uma precisão de 60,87%.

Já em [14], foi desenvolvido um sistema de reconhecimento de emoções através da análise de voz, utilizando técnicas de *machine learning* e processamento de áudio. Com base no conjunto de dados RAVDESS, que contém gravações de emoções como felicidade, tristeza e raiva, o sistema utilizou algoritmos como *Multi-Layer Perceptron* (MLP) para classificar emoções, alcançando 75% de precisão. Este método envolveu a extração de características acústicas, usando a biblioteca Librosa, como coeficientes MFCC, *Chroma* (característica que captura informações de tonalidade), espectrogramas Mel (representam a intensidade das frequências ao longo do tempo), e ainda energia e *pitch*, e o treino de modelos para prever emoções a partir de ficheiros de áudio. A aplicação desta tecnologia em áreas como cidades inteligentes, saúde e segurança adquiriu uma grande importância neste estudo, a par da abordagem de desafios como ruídos de fundo, sotaques e a necessidade de melhorar a precisão em cenários reais.

Em [15], por sua vez, o foco recai sobre as diferentes técnicas de extração de características da voz, analisando o desempenho de diferentes métodos e algoritmos, destacando as respetivas vantagens e limitações. Deste modo, várias técnicas são analisadas, como o *Linear Predictive Coefficients*, o *Linear Predictive Cepstral Coefficient*, o MFCC e ainda o *Relative Spectra*. O artigo compara o desempenho dos modelos em termos de precisão, resistência ao ruído e complexcidade computacional, pelo que o MFCC e o RASTA destacaram-se pela sua precisão e capacidade de operar em ambientes ruidosos, enquanto que os restantes dois modelos tiveram como pontos fortes a simplicidade dos mesmos sendo, no entanto, menos robustos.

3. Métodos utilizados

Neste projeto, foi utilizado um *dataset* retirado da plataforma *GitHub*, que continha gravações de áudio de 24 atores [16]. Cada ator tinha 60 gravações, representando uma gama de emoções básicas: neutro, felicidade, tristeza, medo, raiva, nojo, surpresa e calmo. No total, o *dataset* era composto por 1440 áudios. Cada áudio tinha no seu nome um código, com sete parâmetros, como por exemplo "03-01-01-01-01-01-08". O primeiro e o segundo número representavam o *path* e *source*, respetivamente. O terceiro representa a emoção, sendo que cada emoção anteriormente referida tinha um valor, de 1 a 8, isto é, 01

corresponde a neutro; 02 a calmo; 03 a felicidade; 04 a tristeza; 05 a raiva; 06 a medo; 07 a nojo; 08 a surpresa.

O quarto número demonstra a intensidade (01: baixa, 02: alta), o quinto o tipo de frase (01 ou 02), o sexto a repetição (01 ou 02) e, por último, o número do ator que está presente no áudio (de 01 a 24). Caso o número do ator for par, este é mulher. Caso contrário, é homem.

A escolha do *dataset* foi ideal, apesar de ser importante referir que a emoção "neutro" está menos presente que as restantes, dado que cada ator a interpretou quatro vezes, enquanto as remanescentes perfazem um total de oito áudios. Contudo, este oferecia uma ampla variedade de emoções interpretadas por diferentes indivíduos, permitindo que o modelo fosse treinado com dados diversificados, fator essencial para aprimorar tanto a precisão quanto a robustez. Sabe-se que o desempenho de modelos de *machine learning* é limitado pela qualidade dos dados. Além disso, um dos aspetos fundamentais antes de utilizar conjuntos de dados em qualquer aplicação é compreender o seu conteúdo, uma vez que a falha desse entendimento pode levar a análises imprecisas e decisões pouco confiáveis [17].

4. Metodologia

A *pipeline* do projeto foi dividida em três etapas principais: preparação dos dados, treino e testes, e obtenção de resultados (Fig. 1).

Na etapa de preparação dos dados, os áudios são extraídos e normalizados utilizando os *scripts dataset.py* e *generate_scaler.py*. As características extraídas são armazenadas numa base de dados, que foi ampliada com técnicas de aumento de dados, e guardada em *ravdess_dataset_augmented.csv*.

Na etapa de treino e testes, os dados foram divididos em conjuntos para treino e validação. O treino dos modelos é feito no *script train_and_test.py*, que criou e treinou o modelo, que passou por uma avaliação de desempenho para identificar a versão otimizada, que foi armazenada como modelo final.

Por fim, na etapa de resultados, o modelo otimizado foi utilizado para deteção e classificação de emoções através de áudios, em tempo real, implementadas no *script real_time_test.py*.

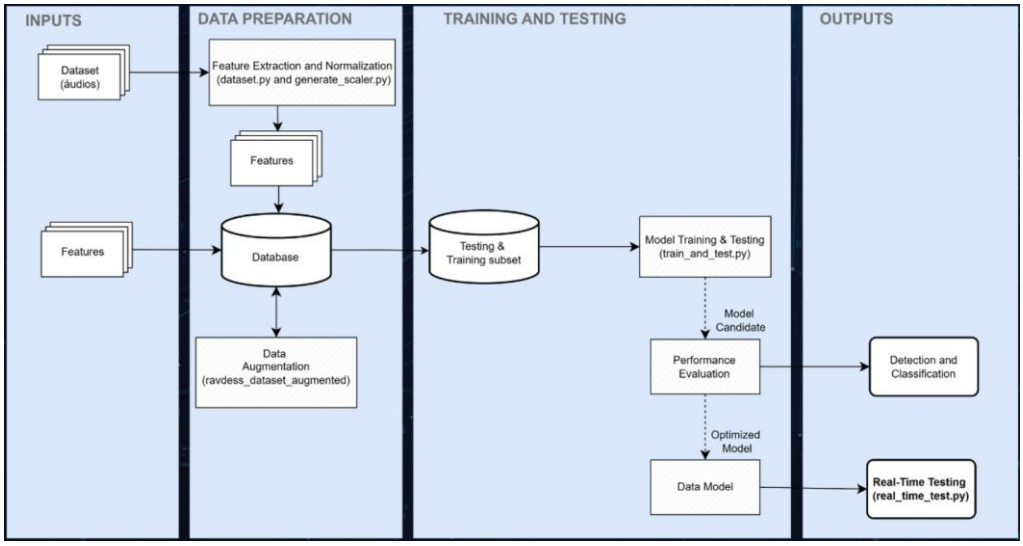

Figura 1. Pipeline utilizado para desenvolvimento do projeto.

O primeiro *script* desenvolvido foi o *dataset.py*, para as duas abordagens (bibliotecas Librosa e OpenSMILE) utilizadas ao longo do projeto. Numa primeira abordagem, foi utilizada a biblioteca Librosa para extrair características acústicas personalizadas dos áudios do *dataset* escolhido. Neste *script* são percorridos os caminhos para identificar os ficheiros

e as suas respetivas emoções, criando o ficheiro *data_path.csv* com essas informações organizadas. A extração das características é bastante detalhada e personalizada, abrangendo métricas como *Zero Crossing Rate* (ZCR), MFCC's, *Mel Spectrogram* e *Spectral Contrast*. Para além disto, este *script* implementa três técnicas de aumento de dados (*data augmentation*): adição de ruído, modificação no tempo (*stretching*) e alteração do *pitch*, de forma a aproximar os áudios de situações reais. Cada áudio é processado na versão original e em duas versões aumentadas, resultando num aumento significativo do número de amostras disponíveis para o treino do modelo. As características extraídas são armazenadas num *dataframe* e guardadas no ficheiro *ravdess_dataset_augmented.csv*, referido anteriormente. Assim, o *script* origina um *dataset* mais robusto e diversificado, incorporando variações nos dados que podem melhorar a generalização dos modelos treinados posteriormente.

Por outro lado, a segunda abordagem utiliza a biblioteca OpenSMILE para processar os áudios do *dataset* RAVDESS e extrair características acústicas baseadas no conjunto *eGeMAPS*. Inicialmente, tal como na abordagem anterior, os diretórios do *dataset* são percorridos para identificar os áudios e associá-los às emoções correspondentes, criando o *data_path.csv*, que contém os caminhos dos arquivos e as suas emoções. A extração de características é realizada diretamente através da biblioteca OpenSMILE, que gera vetores com características padronizadas para cada áudio. Esses vetores são armazenados junto com os rótulos (*labels*) emocionais num *dataframe*, que posteriormente é guardado como *ravdess_dataset_opensmile.csv*, sendo um processo direto, não incluindo técnicas de aumento de dados, ou seja, cada áudio é processado uma única vez e as suas características são extraídas diretamente.

De seguida, foi desenvolvido o *script generate_scaler.py* com o objetivo de padronizar os dados de entrada do conjunto de dados *ravdess_dataset_augmented.csv*. Primeiramente, carrega-se esse conjunto usando a biblioteca *Pandas*. As características (*features*), que representam os valores numéricos associados aos dados de cada áudio, são separadas da última coluna, que contém as *labels*. De seguida criou-se um objeto *StandardScaler* da biblioteca *scikit-learn*, que foi ajustado aos dados através do método *fit*, calculando os valores médios e desvios-padrão para cada característica, de forma a poder normalizá-las. A padronização transforma os dados para que cada característica tenha média zero e desvio padrão igual a um, o que é essencial para melhorar o desempenho de muitos modelos de aprendizagem automática, garantindo que todas as características tenham a mesma escala. Depois de se ter feito este ajuste, o *scaler* é guardado como *scaler.pkl* usando a biblioteca *pickle*, de modo que possa ser reutilizado posteriormente para padronizar novos dados de teste, garantindo consistência na transformação.

O script *model.py* foi criado de forma a criar e a retornar um modelo de rede neuronal convolucional (CNN) utilizando a biblioteca *TensorFlow/Keras*. Em relação à arquitetura, o modelo apresenta diversas camadas. As camadas iniciais utilizam 256 filtros com tamanho de *kernel* 8 e ativação *relu*, seguidas por uma segunda camada convolucional com normalização através de *BatchNormalization* para estabilizar o treinamento e um *Dropout* de 25%, que desativa neurónios de forma aleatória para fins de regularização. Em seguida, há um bloco de camadas consecutivas com 128 filtros e ativação *relu*, responsável por extrair características mais detalhadas dos dados. Outro bloco adicional combina a normalização em lote, *Dropout* e *MaxPooling* com tamanho de *pool* 8, reduzindo a dimensionalidade e preservando as características mais importantes.

A arquitetura conclui-se com camadas convolucionais finais de 64 filtros, seguidas por uma camada *Flatten*, que transforma a saída tridimensional num vetor unidimensional, conectando a uma camada densa com 8 neurónios e ativação *softmax*. Esta última camada é responsável por classificar os dados nas 8 emoções. Finalmente, o *script* guarda o modelo, de forma a que este seja utilizado mais tarde para o treino.

O script *train_and_test.py*, tal como o nome indica, tem como função treinar e avaliar uma rede neuronal para classificação de emoções, a partir do *dataset*.

Primeiramente, os dados de entrada são processados e atribuídos a variáveis (características da voz), bem como os rótulos das emoções que, por sua vez, serão transformados

numa matriz binária de modo a que o modelo consiga lidar com os mesmos. Deste modo, os rótulos binarizados são então guardados sob a forma de um ficheiro *encoder.pkl* de modo a que seja possível reutilizá-los futuramente.

Seguidamente, os dados já processados são divididos para o modelo ser treinado e testado. Assim, 70% dos dados foram destacados para o treino, 15% para teste e os restantes 15% para a realização de validações. Após a divisão estar definida, os mesmos são normalizados e ainda expandidos para que o formato dos dados de entrada corresponda ao esperado pelo modelo.

No processo de treino propriamente dito, o otimizador *Adam* e a função de perda *categorical_crossentropy* assumem-se como elementos centrais neste processo. O primeiro é um parâmetro comumente usado em projetos de *deep learning*, pelo que a sua principal função prende-se por ajustar os pesos do modelo com base nos gradientes calculados a partir da função de perda, de modo a acelerar a convergência e melhorar a estabilidade em problemas complexos. O segundo, por sua vez, tem como principal objetivo medir a diferença entre as distribuições previstas pelo modelo e os rótulos reais, penalizando fortemente previsões distantes dos rótulos verdadeiros, incentivando o modelo a atribuir alta probabilidade à classe verdadeira. O número de épocas, isto é, a quantidade de vezes que o modelo passa pelo *dataset*, foi minuciosamente definido de modo a que a partir do momento em que se sucedesse uma estabilização dos parâmetros de treino, o treino terminava, para que o risco de ocorrência de *overfitting* fosse mitigado. Outro pilar do treino do algoritmo passa pela existência de um *callback*, o *ReduceLROnPlateau*, que permite que personalizar o treino do modelo de forma dinâmica, isto é, ajusta o valor da taxa de aprendizagem (*learning_rate*) para que, caso o algoritmo encontre um mínimo local durante o processo de treino, e permaneça um número previamente definido de épocas sem melhorias evidentes o valor desse parâmetro seja multiplicado por um fator (definido como 0.8) para que evite uma estagnação do procedimento.

Finalmente, o modelo é guardado para utilizações futuras na previsão das emoções. O algoritmo apresenta uma matriz confusão dos resultados, bem como os parâmetros inerentes à mesma: *Precision*, *Accuracy*, *Recall* e *F1-Score*. Além disso, são ainda gerados dois gráficos que mostram a evolução da *Accuracy* bem como a progressão da função de perda ao longo do treino.

Por último, encontra-se o *script real_time_test.py* e, tal com o nome indica, serve para testar em tempo real um áudio fornecido ao modelo que, por sua vez, é carregado antes do teste propriamente dito, juntamente com o *scaler.pkl* que, tal como mencionado anteriormente, normaliza as características da voz. Deste modo, torna-se importante referir que a preferência por áudios previamente gravados face à captação da fala ao vivo é justificada por diversas vantagens, como o controlo mais rigoroso da qualidade do som, a consistência na análise, a redução de interferências causadas por ruídos ambientais e a possibilidade da realização de testes e ajustes em condições controladas. Esta abordagem permite uma maior eficiência no processamento e evita problemas associados a variações na captação da fala em tempo real, garantindo deste modo resultados mais precisos e com maior fiabilidade.

Assim, de modo a garantir resultados consistentes, o processamento do ficheiro áudio é igual ao que acontece na fase de treino. O arquivo indicado é processado de forma a extrair as suas características relevantes, que são normalizadas pelo *scaler.pkl* e redimensionadas para que o seu formato seja compatível com a entrada do modelo. Após este processo, as mesmas são enviadas para o modelo, que retorna uma matriz de probabilidades associadas a cada emoção possível. A classe com maior probabilidade é selecionada como a previsão definitiva, sendo descodificada pelo *encoder.pkl* permitindo assim a interpretação direta do resultado.

5. Resultados e Avaliação

Nesta secção serão apresentados os resultados obtidos em cada uma das abordagens referidas. Na Tabela 1 está representado o desempenho entre as bibliotecas Librosa e OpenSMILE na extração de características para classificação de emoções em áudios, permitindo fazer uma comparação entre as mesmas. Para a Librosa, os resultados mostram uma acurácia de 80%, com precisão de 82%, *recall* de 80% e um *F1-Score* de 80%, evidenciando um desempenho robusto na classificação das emoções. Por outro lado, o OpenSMILE obteve uma acurácia de 63%, com precisão de 67%, *recall* de 63% e um *F1-Score* de 63%, demonstrando um desempenho inferior em comparação com o Librosa.

Desta forma, estes resultados, bem como os testes efetuados, destacam a superioridade do Librosa no contexto específico deste estudo, sugerindo que a sua abordagem de extração de características pode ser mais adequada para a tarefa de reconhecimento emocional em áudios, pelo menos com os dados e parâmetros utilizados nesta análise.

Tabela 1. Resultados obtidos para as duas abordagens utilizadas.

Biblioteca	***Accuracy***	***Precision***	***Recall***	***F1-Score***
Librosa	80%	82%	80%	80%
OpenSMILE	63%	67%	63%	63%

As matrizes de confusão de cada biblioteca ilustram os acertos e erros na previsão das emoções, enquanto que as métricas de desempenho quantitativas, registadas na Tabela 1, permitem avaliar a eficácia de cada abordagem. A matriz de confusão do modelo que utilizou a biblioteca Librosa, está apresentada na Figura 2 a), e permite observar que esta tem um desempenho mais consistente na classificação das emoções. Por exemplo, a emoção calmo, em inglês *calm*, foi corretamente classificada em 83 casos, enquanto que as emoções zangado e feliz, em inglês *angry* e *happy*, obtiveram 66 e 67 classificações corretas, respetivamente. No geral, os erros de classificação são mais concentrados em poucas categorias, refletindo uma precisão global mais elevada da biblioteca.

Já no caso do modelo que utilizou o OpenSMILE, os resultados não são tão satisfatórios. A matriz de confusão respetiva está apresentada na Figura 2 b), de onde se pode verificar que a emoção *surprise* foi classificada corretamente em 69 casos, sendo essa a emoção com maior número de classificações acertadas.

Assim, e para ambas as bibliotecas, é notória o número reduzido de amostras para a emoção neutro, reflexo da menor presença da mesma aquando do teste do modelo, como já explicado anteriormente. Deste modo, é natural que ao utilizar novos dados para teste fora do *dataset* original, o desempenho para esta categoria seja inferior em comparação às demais emoções, tendo o modelo mais dificuldade em prevê-la, dada a pouca presença da mesma no treino do algoritmo.

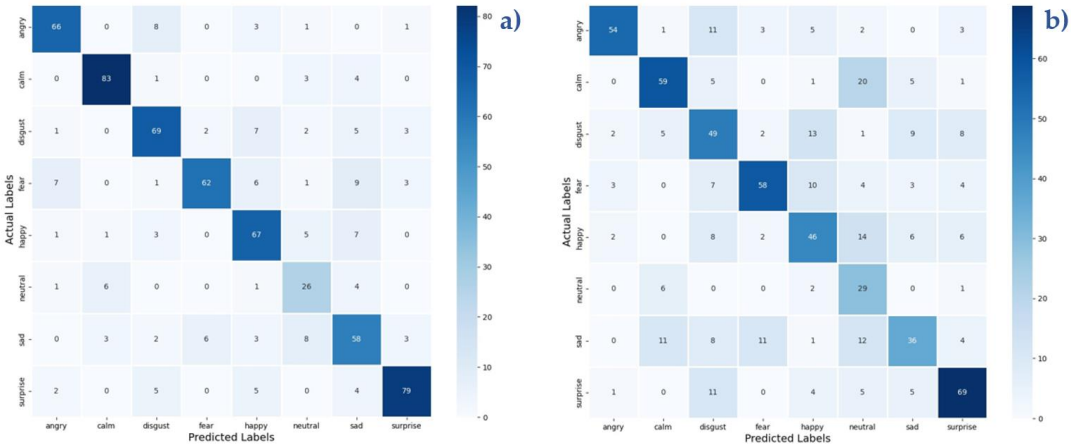

Figura 2. Matrizes de confusão: a) Librosa, e, b) OpenSMILE.

6. Conclusão e Trabalhos Futuros

O nosso trabalho apresentou uma comparação oportuna entre dois métodos de extração de *datasets*, utilizando as bibliotecas Librosa e OpenSMILE. A análise permitiu compreender as vantagens e limitações de cada abordagem, reforçando a sua aplicabilidade em contextos de processamento de áudio e *machine learning*. A construção e o treinamento do modelo reforçaram a eficácia do uso de CNNs em aplicações que envolvem o reconhecimento de emoções através da voz, em áudios. Fora isso, os resultados foram satisfatórios, uma vez que o melhor resultado apresentado atingiu uma *accuracy* de 80%, e o modelo conseguia identificar emoções corretamente em áudios variados.

Relativamente a sugestões futuras, diversas melhorias podem ser implementadas. Primeiramente, o *dataset* utilizado poderia ser ampliado e diversificado, incluindo amostras de diferentes idiomas, faixas etárias, géneros e sotaques, com o objetivo de aumentar a robustez e a generalização do modelo. Adicionalmente, seria interessante explorar o uso de modelos mais avançados, como RNNs ou combinações de redes convolucionais e recorrentes (CNN-RNN), que possuem potencial para melhorar a precisão na classificação de dados de áudio.

Outra possível evolução seria adaptar o sistema para realizar deteções em tempo real, enfrentando cenários desafiadores como ambientes com ruído de fundo e outras condições adversas. Isso exigiria otimizações no desempenho do modelo e na sua integração com sistemas de hardware de baixa latência.

Finalmente, este projeto foi valioso para aprofundar conhecimentos em áreas fundamentais de *machine learning*. O desenvolvimento do projeto proporcionou também uma aprendizagem prática sobre redes neuronais, técnicas de pré-processamento de dados e a importância de selecionar métodos de extração de características adequados.

References

[1] E. Frant¸i et al., "Voice Based Emotion Recognition with Convolutional Neural Networks for Companion Robots," 2017.

[2] B. Mcfee et al., "librosa: Audio and Music Signal Analysis in Python," 2015. [Online]. Available: https://www.youtube.com/watch?v=MhOdbtPhbLU

[3] M. K. Reddy, P. alku, and K. S. Rao, "Detection of Specific Language Impairment in Children Using Glottal Source Features," IEEE Access, vol. 8, pp. 15273–15279, 2020, doi: 10.1109/aCCESS.2020.2967224.

[4] C. M. Tyng, H. U. Amin, M. N. M. Saad, and A. S. Malik, "The influences of emotion on learning and memory," Aug. 24, 2017, Frontiers Media S.A. doi: 10.3389/fpsyg.2017.01454.

[5] P. Ekman, "An-Argument-For-Basic-Emotions," Cogn Emot, vol. 6, no. 4, pp. 169–200, 1992.

[6] L. Josephs, "Book Reviews: Emotions Revealed: Recognizing Faces and Feelings to Improve Communication and Emotional Life, by {TC \11"} Paul Ekman. Henry Holt and Company, New York, 2004, 274 pp.," The American Journal of Psychoanalysis, vol. 65, no. 4, pp. 409–411, Dec. 2005, doi: 10.1007/s11231-005-7891-8.

[7] J. A. Russell, "Core Affect and the Psychological Construction of Emotion," Psychol Rev, vol. 110, no. 1, pp. 145–172, 2003, doi: 10.1037/0033-295X.110.1.145.

[8] J. A. Russell, "A circumplex model of affect," J Pers Soc Psychol, vol. 39, no. 6, pp. 1161–1178, Dec. 1980, doi: 10.1037/h0077714.

[9] M. Spezialetti, G. Placidi, and S. Rossi, "Emotion Recognition for Human-Robot Interaction: Recent Advances and Future Perspectives," Dec. 21, 2020, Frontiers Media S.A. doi: 10.3389/frobt.2020.532279.

[10] V. Govindaraju and D. Thangam, "Emotion recognition in Human-Machine interaction and a review in interpersonal communication perspective," in Human-Machine Collaboration and Emotional Intelligence in Industry 5.0, IGI Global, 2024, pp. 329–343. doi: 10.4018/979-8-3693-6806-0.ch018.

[11] S. R. Livingstone and F. A. Russo, "The Ryerson Audio-Visual Database of Emotional Speech and Song (RAVDESS): A dynamic, multimodal set of facial and vocal expressions in North American English," 2018, doi: 10.5281/zenodo.1188976.

[12] R. Cowie and R. R. Cornelius, "Describing the emotional states that are expressed in speech," Speech Commun, vol. 40, no. 1–2, pp. 5–32, Apr. 2003, doi: 10.1016/S0167-6393(02)00071-7.

[13] S. Chamishka et al., "A voice-based real-time emotion detection technique using recurrent neural network empowered feature modelling," Multimed Tools Appl, vol. 81, no. 24, pp. 35173–35194, Oct. 2022, doi: 10.1007/s11042-022-13363-4.

[14] R. Rastogi, T. Anand, S. K. Sharma, and S. Panwar, "Emotion Detection via Voice and Speech Recognition," International Journal of Cyber Behavior, Psychology and Learning, vol. 13, no. 1, 2023, doi: 10.4018/IJCBPL.333473.

[15] S. Graf, T. Herbig, M. Buck, and G. Schmidt, "Features for voice activity detection: a comparative analysis," EURASIP J Adv Signal Process, vol. 2015, no. 1, Dec. 2015, doi: 10.1186/s13634-015-0277-z.

[16] S. Mulajkar, "Audio_Speech_Actors_01-24/Actor_01 at main · sidmulajkar/sentiment-predictor-for-stress-detection." Accessed: Jan. 04, 2025. [Online]. Available: https://github.com/sidmulajkar/sentiment-predictor-for-stress-detection/tree/main/Audio_Speech_Actors_01-24/Actor_01

[17] Abhinav Jain et al., "Overview and Importance of Data Quality for Machine Learning Tasks," in Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery &amp, New York, NY, USA, 2020, pp. 3561–3562.